

// PROJECT - BJ-PAL

周六下午的 决策解药

CODENAME

BJ-Pal · 北京搭子

Jason Xun · KeepL · 2026.05 · github.com/estelledc/bj-pal

A SHORT-TERM ACTIVITY PLANNING AGENT

短期活动规划与执行 · 情绪基础设施

FINALS · 决赛入围

SCENE - 周六 14:00 · 朝阳

"周六下午，小明把手机递给对象问
'你看这样行不'。"

"30 秒后对象说：'换一个'。"

100 条 AI 用户访谈 · 5/5

约出门最卡的不是讨论时间，
是没人愿意承担选错的风险。

// THE ONE INSIGHT

用户付钱不是为"规划方案",
是为"**AI 替我扛了选错的责任**"。

这是**情绪基础设施**, 不是工具产品。

100 条访谈, 5 个强信号

N=100 · 决策性信号阈值 ≥ 4/5

SIGNAL · 01

5/5

选错责任
是群决策的痛

RESPONSIBILITY

SIGNAL · 02

5/5

必须看到吐槽
不只是分数

UGC SOFT-SIGNAL

SIGNAL · 03

5/5

选错容忍度
= 2 次

ERROR BUDGET

SIGNAL · 04

4/5

工作日
不属于这个 App

SCOPE BOUNDARY

SIGNAL · 05

5/5

重要场合 = 工具
不是代理

AGENT BOUNDARY

Plan-and-Execute 流水线

USER INPUT → PLANNER → PROBE → REPLANNER → MOCK ORDER → IM CARD



REAL-WORLD GROUNDING · 真实场景 Grounding

真实北京，不是 demo 假数据

客观 POI facts + 主观 UGC soft signals + 用户访谈形成的需求先验，让每个候选都能落到 reasons[] / evidence[]。

01 · POI

5,656

北京真实 POI

POI facts · 坐标/评分/营业/价格

02 · UGC

8,666

UGC soft signals

排队/拥挤/停车/吐槽 · red flags

03 · SIGNAL

5,198

POI 信号网

facility / seasonal / parking / crowd

04 · INT

100

AI 用户访谈

需求先验 · 不是想象出来的 pain

不是路线生成器，是被真实世界校准过的决策代理。

EVIDENCE-LED PLANNING

可解释 · 可溯源 · 每条候选都有理由

SCORE FORMULA

score = 0.35 · amap_rating + 0.30 · ugc_soft+ + 0.15 · budget_fit + 0.10 · distance + 0.10 · crowd_penalty



+ REASONS / EVIDENCE 每条候选附 reasons[] + evidence[], 引用 UGC 原文片段, 可点击溯源

14:00 · 系统替你改主意

RISK DETECTED → REPLAN IN 1 SECOND

STEP · 01

原方案

14:00 · ITEM_A

五道营胡同

逛街 / 拍照 / 文创小店

score · 0.71



STEP · 02 · 风险检测

AvailabilityProbe

▲ RISK SIGNALS

UGC[crowd] · 周末下午爆棚
排队 30+ 分钟

UGC[transport] · 不好停车
周边均无车位

REROUTE TRIGGERED · 1.2s



STEP · 03

新方案 · v2

14:00 · ITEM_A'

国子监

慢逛 / 院落 / 不挤 · 距离 +400m

score · 0.83 ↑

UI 上：时间轴卡片 原地替换，附风险标签 + reasons 浮层

EVAL METHOD · RUBRIC · LONGCAT CASES

评测方法：Rubric + 三层回归

先用 TravelPlanner 四指标判一次，再用 S1-S5 deterministic checks 查真实使用风险；版本对比只比较技术方案增量。

01 · RUBRIC

100 LONGCAT CASES

TravelPlanner 四指标

delivery_rate

计划非空 + JSON 合法

commonsense_pass

时间顺序 / 餐时 / 地理常识

hard_constraint_pass

预算 / 时段 / 人数 / 忌口

final_pass

四项同时通过，才算用户级通过

02 · VERSION DELTA

v1 = 裸 Planner 基线

v2 = Planner + AvailabilityProbe

v3 = Planner + AvailabilityProbe + Replanner + IM 卡片

03 · SIGNAL CHECKS

S1-S5 deterministic checks

trace / red flags / apology / weekday / screening

04 · RESULTS

27.5% → 47.0%

L3 280/280 · ECE 0.1089 · +71% final_pass

L1 · STEP-LEVEL

每 commit 30s 冒烟 · mock 兜底

L2 · PLAN-LEVEL

5 模块 × 5 case · 行为基线

L3 · USER-LEVEL

100 case × 5 信号 · 280 检查

CALIBRATION

Global ECE 0.1089 · target ≤ 0.15

BJ-PAL · 09 / 10

两位作者， + 一个 AI 协作者

// STACK

Python · LangGraph · LongCat · ToT · OPTW ·
Kemeny+Borda · OTel · Streamlit

// EVAL PYRAMID



// TEAM

Jason Xun · KeepL

黑客松作者 · 30 天快速迭代
+ Claude Code 全程协作

SOURCE

github.com/estelledc/bj-pal

谢谢 · THANK YOU